

# Sistemas Inteligentes - Appunti

Francesco Lorenzoni

Febrero 2025



# Contents

<b>I</b>	<b>Introduction to SIN</b>	<b>5</b>
<b>1</b>	<b>Introduction</b>	<b>9</b>
1.1	Informaciones generales . . . . .	9
1.2	Inteligencia Artificial . . . . .	10
1.2.1	Aplicaciones de la IA . . . . .	10
<b>2</b>	<b>Planificación Inteligente</b>	<b>11</b>
2.0.0.1	Modelo “planificación clásica” . . . . .	12
2.1	Planificación Jerárquica . . . . .	12
<b>3</b>	<b>Pyhop</b>	<b>13</b>
<b>4</b>	<b>Optimización Inteligente</b>	<b>15</b>
4.1	Scheduling . . . . .	15
4.1.1	JSP . . . . .	15
4.1.2	CSP - Constraint Satisfaction Problem . . . . .	15
4.1.3	Algoritmo Genéticos . . . . .	16
4.1.3.1	Resumen . . . . .	16
<b>5</b>	<b>Agente Inteligentes</b>	<b>19</b>
5.1	Jason . . . . .	20
5.1.1	Creencias . . . . .	20
5.1.2	Objetivos . . . . .	20
5.1.3	Planes . . . . .	21
5.1.3.1	Cuerpo de un plan . . . . .	21
5.1.3.2	Fallo de un Plan . . . . .	21
5.1.4	Ejemplos . . . . .	21
<b>6</b>	<b>Ontologías</b>	<b>23</b>
<b>II</b>	<b>Machine Learning</b>	<b>25</b>
<b>7</b>	<b>N-Grams y FSA</b>	<b>27</b>
7.1	N-Grams . . . . .	27
7.2	FSA - Finite State Automata . . . . .	28
7.2.1	Applications of PFA . . . . .	29
7.2.2	Relation between N-Grams and PFA . . . . .	30
7.3	Relación entre N-Grams y PFA . . . . .	30
<b>8</b>	<b>Deep Learning</b>	<b>31</b>
8.1	Introducción . . . . .	31
8.2	Linear Discriminant Function and Perceptron . . . . .	31



## Part I

# Introduction to SIN



---

<b>1</b>	<b>Introduction</b>	<b>9</b>
1.1	Informaciones generales . . . . .	9
1.2	Inteligencia Artificial . . . . .	10
1.2.1	Aplicaciones de la IA . . . . .	10
<b>2</b>	<b>Planificación Inteligente</b>	<b>11</b>
2.1	Planificación Jerarquica . . . . .	12
<b>3</b>	<b>Pyhop</b>	<b>13</b>
<b>4</b>	<b>Optimización Inteligente</b>	<b>15</b>
4.1	Scheduling . . . . .	15
4.1.1	JSP . . . . .	15
4.1.2	CSP - Constraint Satisfaction Problem . . . . .	15
4.1.3	Algoritmo Genéticos . . . . .	16
<b>5</b>	<b>Agente Inteligentes</b>	<b>19</b>
5.1	Jason . . . . .	20
5.1.1	Creencias . . . . .	20
5.1.2	Objetivos . . . . .	20
5.1.3	Planes . . . . .	21
5.1.4	Ejemplos . . . . .	21
<b>6</b>	<b>Ontologías</b>	<b>23</b>

---





# Chapter 1

## Introduction

### 1.1 Informaciones generales

En los Viernes las clases son online y sincronas.

La asignatura se divide en does partes:

1. Parte 1

T1 Introducción

T2 Planificación inteligente

Algunos ejemplos son la planificación de procesos/planes de producción, o la planificación de rutas de reparto y logística; en general, aplicaciones incluyen sistemas de ayuda a la toma de decisiones y recomendación.

T3 Optimización inteligente Optimización de la logistica empresarial (horarios, recursos, personal, turnos de trabajo,...)

T4 Agentes inteligentes Sistemas multiagentes que tienen que negociar, coordinarse y cooperar para un objetivo común. Pero algo videojuegos donde existe una competición o cooperación entre agentes y se requiere una búsqueda de alternativas.

2. Parte 2

T5 Modelado de lenguaje y autómatas finitos

T6 Aprendizaje profundo

T7 Aprendizaje profundo para clasificación de texto

T8 Aprendizaje profundo para clasificación de imágenes

Profesor	T1	T2	T3	T4	T5	T6	T7	T8
Jaume Jordán								
Carlos Carrascosa								
Carlos Martínez (resp.)								

Figure 1.1: Profesores

La evaluación se efectuará mediante:

- ◇ Dos tests (**20 de junio a las 15:30**) sobre contenidos teóricos y prácticos de la parte 1 (15%) y parte 2 (15%), totalizando 30%.
- ◇ Trabajos académicos (70%):
  - Parte 1 (35%): tema 2 (15%) y tema 4 (20%).
  - Parte 2 (35%): tema 5 (10%), tema 7 (10%) y tema 8 (15%).

## 1.2 Inteligencia Artificial

IA no es solo IA generativa. IA es un campo muy amplio que incluye otras cosas. Inicialmente se asociaba con el Machine Learning, pero ahora se ha ampliado a otras cosas.

La Inteligencia Artificial es un campo interdisciplinario que implica máquinas capaces de imitar determinadas funcionalidades de la inteligencia humana, incluidas características como la percepción, el aprendizaje, el razonamiento, la resolución de problemas, la interacción lingüística e incluso la producción de trabajos creativos.

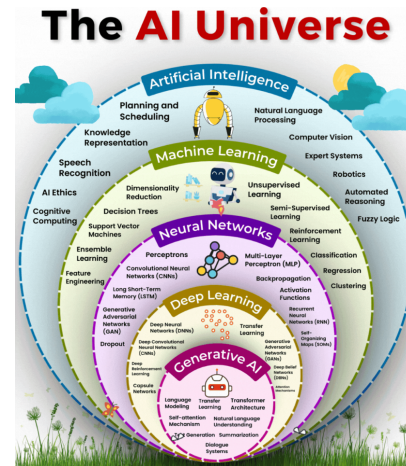


Figure 1.2: AI esquema. Según el profesor esto esquema no es completo, pero es ilustrativo.

Modelos de IA:

- ◊ Aprendizaje supervisado
- ◊ Aprendizaje no supervisado
- ◊ Aprendizaje por refuerzo

### 1.2.1 Aplicaciones de la IA

La Inteligencia artificial puede ser útil para estas cosas: Áreas y aplicaciones

- ◊ Recuperación inteligente de la información
  - Recuperación de información no explícitamente representada
  - Bases de datos deductivas. Procesos inferenciales. Sentido común. Interfaz natural
- ◊ Ingeniería del conocimiento (SBC y Sistemas Expertos)
  - Problemas NP: restricción de dominios, heurísticas y meta-heurísticas
  - Planificación. Scheduling. Optimización. Sistemas de Ayuda a la Toma de Decisiones
- ◊ Problemas (de búsqueda) combinatorios y de planificación
  - Problemas NP: restricción de dominios, heurísticas y meta-heurísticas
  - Planificación. Scheduling. Optimización. Sistemas de Ayuda a la Toma de Decisiones

Hay también otras aplicaciones

- ◊ Sistemas Multiagente y distribuidos que interactúan (cooperación)
- ◊ Robótica
- ◊ Percepción
- ◊ Procesamiento de lenguaje natural

## Estado inicial

Información estática	Información dinámica
distance[home][airport_city1]=15 distance[home][center_city1]=5 distance[home][connection_c1_c2]=2 ..... vehicles(taxi)={taxi1} vehicles(plane)={plane1} ... location(airport)={airport_city1, airport_city2} location(to_stay)={home, hotel_city2, ...} .... city(home)=city1 city(airport_city1)=city1 city(airport_city2)=city2 .....	at(me)=home at(taxi1)=center_city1 at(plane1)=airport_city1 at(car1)=home cash(me)=20 ;; dinero que tengo owe(me)=0 ;; dinero que debo

### Objetivos

at(me)=hotel\_city2

Figure 2.2: Suponen que tengo que viajar desde una ciudad a otra. Esta puede ser una formalización de la planificación.

## Chapter 2

# Planificación Inteligente

Podemos ver la Planificación Inteligente desde varios puntos de vista:

- ◊ Deducción  
A partir de algunos hechos ciertos, conocer qué otros hechos también son ciertos (propagación)
- ◊ Aprendizaje  
“Mejorar la conducta a partir de la experiencia”
- ◊ Razonamiento sobre acciones A partir de algunos hechos ciertos (estado inicial), decidir qué acciones se deben ejecutar para alcanzar ciertos objetivos (es decir, que otros hechos sean también ciertos) en base a relaciones de causa-efecto.

El ser humano es inteligente porque es capaz de razonar acerca de las consecuencias de sus actos. Al fin y al cabo estamos planificando constantemente aunque no nos demos cuenta.

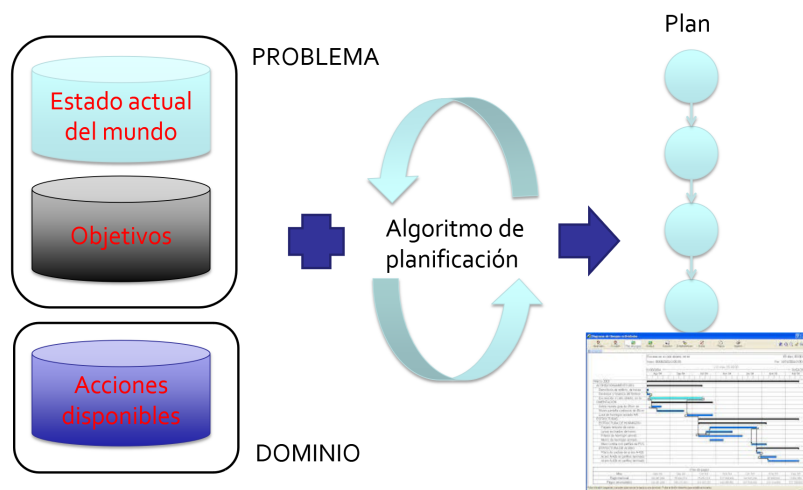


Figure 2.1: Planificación esquematizada

En Fig. 2.1 podemos ver un esquema de planificación. En el estado actual del mundo corresponde al “*dominio*”, y el objetivo es llegar a un estado deseado en el mundo.

**Definition 2.1 (Plan)** *Un plan  $P$  es una secuencia de acciones que transforma el estado inicial ( $I$ ) en un estado que satisface los objetivos ( $G$ )*

Un plan puede estar parcial o totalmente ordenado. Un enlace causal  $(a_i, p, a_j)$  determina que la acción  $a_i$  resuelve la condición  $p$  de la acción  $a_j$ .




Figure 2.4: Plan

### 2.0.0.1 Modelo “planificación clásica”

- ◇ Determinista
- ◇ Estático (solo cambia por las acciones)
- ◇ Completamente observable
- ◇ Razonamiento temporal y numérico no contemplado

Es decir, el resultado de una acción aplicada a un estado completamente conocido se puede predecir correctamente, ya que no hay influencias externas que afecten al entorno. Para resolver este problema se utilizan algoritmos de búsqueda.

Este modelo pero es muy limitado, y sus asunciones necesitan ser relajadas para que sea más realista y aplicable a problemas reales.

En primer lugar, las acciones tienen distintas **duraciones**, usan recursos y tienen **coste**; además, El mundo *no* es totalmente conocido (existe incertidumbre) y es **dinámico** (cambia debido a eventos exógenos).

## 2.1 Planificación Jerárquica

La idea principal de **HTN** Hierarchical Task Network planning es proceder de una forma más parecida a como los humanos resolvemos los problemas complejos: Primero los aspectos generales (tareas) y después los detalles.

Se definen métodos abstractos que se deben descomponer para resolver el problema. Métodos son los triángulos invertidos en la figura.

Cada método incluye estos componentes:

- ◇ Nombre
- ◇ Parámetros
- ◇ Precondiciones
- ◇ Red de tareas




Figure 2.5: Método abstracto y descomposición

Métodos son tareas a descomponer, y los operadores (como **Fly**) representan las acciones que se pueden llevar a cabo dentro del mundo para poder alcanzar los distintos objetivos (acciones ejecutables que producen cambios en el estado del mundo).

- ◇ Nombre
- ◇ Parámetros
- ◇ Condiciones
- ◇ Efectos

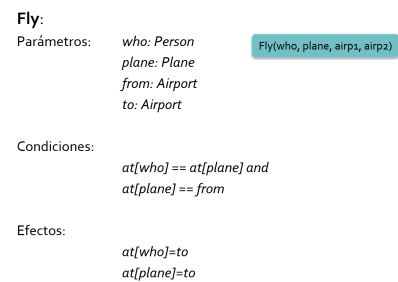


Figure 2.6: Acción Fly

## Chapter 3

# Pyhop

Para resolver un problema tenemos tres fases

1. Modelato
2. Planificación
3. Ejecución

El problema se define como una declaración de un nuevo estado del mundo (inicial), y una declaración de un objetivo. El **dominio**, son las acciones disponibles, que se estructuran en dos niveles: tareas/operadores y métodos.

- ◇ Información estática: no cambia durante la ejecución del problema y que sirve de soporte. Por ejemplo: distancias entre ciudades.
- ◇ Información dinámica: representa el estado actual del mundo. Por ejemplo: cantidad de dinero disponible por el agente en un momento determinado

Representan las **acciones ejecutables** en el dominio

```
def nombre_operador(state, otros_parametros):  
    <extracción valores estado>  
    if condicion1 and condicion2 and ... :  
        state.variable = nuevo_valor  
        ...  
        state.variable = nuevo_valor  
        return state  
    else: return False
```

Condiciones

Efectos

**Se devuelve el nuevo estado tras aplicarse el operador  
o False si el operador no es aplicable**

```
pyhop.declare_operators(nombre_todos_operadores)
```

Figure 3.1: Como definir un operador en Pyhop



## Chapter 4

# Optimización Inteligente

Planificación y Scheduling representa un área de gran relevancia en Inteligencia Artificial. Muchos problemas reales se modelan como problemas de P&S.

La planificación es un proceso de deliberación que escoge y organiza acciones anticipando sus resultados o consecuencias.

Lo scheduling es un proceso de asignación de recursos a tareas sobre el tiempo para optimizar uno o más objetivos.

PLANNING	SCHEDULING
La tarea de planificación determina <u>QUÉ</u> acciones son necesarias llevar a cabo para alcanzar un estado objetivo	La tarea de scheduling se centra en <u>CUÁNDO/CÓMO</u> llevar a cabo las acciones para optimizar el problema

Figure 4.1: P&S

## 4.1 Scheduling

Un problema de scheduling consiste en organizar en el tiempo un conjunto de actividades que compiten por el uso limitado de recursos

### 4.1.1 JSP

JSP stands for Job-Shop Scheduling, y es un paradigma de los problemas de scheduling es muy simple de enunciar y muy difícil de resolver.

- ◇  $n$  trabajos cada uno compuesto por un conjunto ordenado de tareas
- ◇  $m$  maquinas donde se procesan las tareas
- ◇ Cada tarea debe ser procesada en una única máquina durante un tiempo determinado y en un orden pre-fijado;
- ◇ El objetivo es minimizar *makespan*: instante de finalización de la última tarea

- ◇ **Datos** -  $p_{ij}$  es el tiempo de proceso de la tarea  $i$  en el trabajo  $j$ ;
- ◇ **Variables** -  $st_{ij}$  es el tiempo de inicio de tarea  $i$  en el trabajo  $j$ ;
- ◇ **Restricciones** -
  - Secuencial -  $st_{ij} + p_{ij} \leq st_{i(j+1)}$
  - Capacidad -  $st_{ij} + p_{ij} \leq st_{kl} \vee st_{kl} + p_{kl} \leq st_{ij}$
  - Sin interrupción -  $C_{ij} = st_{ij} + p_{ij}$
- ◇ **Objetivo** - Construir una ordenación de las tareas en el tiempo de manera que se satisfagan todas las restricciones sobre cada máquina.
  - Minimize the makespan:  $C_{max} = \max C_{ij}$
  - Minimize total flow time:  $C_{sum} = \sum C_{ij}$
  - Minimize makespan + energy

### 4.1.2 CSP - Constraint Satisfaction Problem

Muchos problemas pueden ser expresados mediante:

- ◇ Un conjunto de variables.

- ◊ Un dominio de interpretación (valores) para las variables.
- ◊ Un conjunto de restricciones entre las variables.
- ◊ La solución al problema es una asignación válida de valores a las variables.

Formalization omitted here

En general, los problemas de optimización son particularmente difíciles de resolver. En general, basta con una solución razonablemente buena (factible, optimizada, pero no la óptima) en un tiempo razonable, y si puede obtener con métodos aproximados (como alternativa a los métodos exactos), cómo la **Búsqueda Heurística** / Metaheurística: La solución es obtenida (generada / mejorada), mediante un proceso de búsqueda en un amplio espacio de estados/soluciones.

- ◊ Búsqueda Local (Local Search) - Se parte de una solución inicial y se busca una solución mejor en el vecindario de la solución actual.
- ◊ Búsqueda Sistemática (Systematic Search) - Se parte de una solución inicial y se busca una solución mejor en todo el espacio de soluciones.
- ◊ Métodos Constructivos - Construyen una solución paso a paso, añadiendo o eliminando elementos de la solución.
- ◊ Métodos de Mejora - Parten de una solución inicial y la mejoran iterativamente mediante movimientos locales.
- ◊ Métodos Evolutivos - Combinan soluciones previas

### 4.1.3 Algoritmo Genéticos

Los **algoritmos genéticos** son un tipo de algoritmo evolutivo que se utiliza para encontrar soluciones aproximadas a problemas de optimización y búsqueda. Estos algoritmos reflejan el proceso de selección natural en la evolución de las especies, y se basan en la idea de que las soluciones a un problema pueden ser representadas como individuos en una población, y que la evolución de la población puede conducir a la generación de soluciones cada vez mejores.

La operación fundamental es la **cruce**, que toma  $n$  padres (típicamente 2) y genera  $m$  hijos (típicamente 2); consiste en heredar material genético de los padres. La asunción es que si los padres tienen buen material genético, la mezcla del material genético de ambos también será buena.

Entonces, el efecto de la cruce es *explorar* el espacio de búsqueda con **material prometedor**.

La operación de **mutación** es una operación que se aplica a un individuo y cambia aleatoriamente uno o más genes de ese individuo. Corisponde a una búsqueda local, porque sólo se cambia un gen a la vez, y entonces el hijo será cerca de su padre.

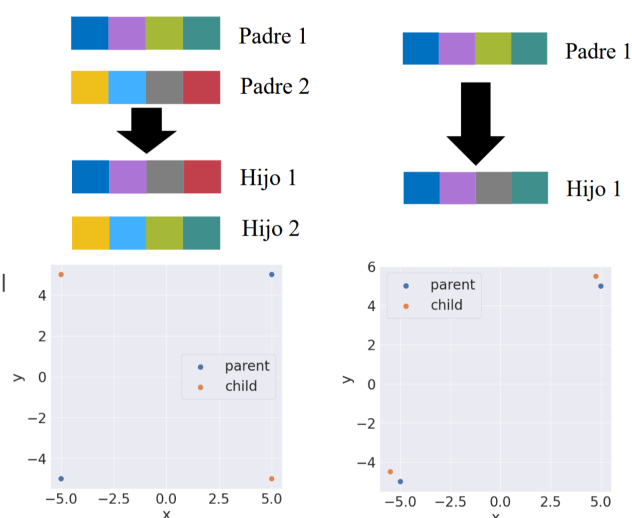


Figure 4.2: Cruce y mutación

TODO selección des padres TODO criterio de parada

#### 4.1.3.1 Resumen

1. Una **representación** adecuada de las *soluciones* del problema (individuos). Cromosomas, genes, genotipo, fenotipo.
2. Una forma de crear una **población de soluciones inicial** (individuos iniciales). A menudo, aleatoria.
3. Una **función de evaluación** capaz de medir la adecuación de cualquier solución (individuo) al problema. Fitness.
4. Un conjunto de **operadores evolutivos** para combinar las soluciones existentes con el objetivo de obtener nuevas soluciones (nuevos individuos): *selección, cruce, mutación y reemplazo* de individuos. Guían el proceso de la búsqueda.
5. Conjunto de **parámetros de entrada**: tamaño de la población, número de iteraciones (generaciones), probabilidades de selección, etc.

Podemos resumir el proceso de un algoritmo genético en los siguientes pasos:

1. **Codificación** de Soluciones/instanciaciones.
2. **Población Inicial**:



- i. Generar población aleatoria de  $n$  individuos:  $x$  (posibles soluciones del problema)
  - ii. Evaluar la aptitud o fitness  $f(x)$  de cada individuo.
3. **Ciclo-Generacional:**
  - i. **Selección** Seleccionar dos padres de la población de acuerdo a su aptitud: Probabilidad de cruce ( $p_c$ ).
  - ii. **Cruce** Combinar los genes de los dos padres para obtener descendientes.
  - iii. **Mutación** Con una probabilidad de mutación ( $p_{mut}$ ), mutar cada gen de los cromosomas hijo.
  - iv. **Reemplazo** Añadir nuevos hijos y determinar nueva población.
4. Verificar condición de parada:
  - i. **Parada:** proporcionar como solución el individuo con mejor valor de aptitud  $f(x)$ .
  - ii. **Ciclo:** Ir al paso 2



## Chapter 5

# Agente Inteligentes

Agentes autónomos trabajan para resolver problemas en un entorno dinámico y complejo. Un agente es un sistema computacional que opera en un entorno y es capaz de percibirlo y actuar sobre él. Un agente inteligente es aquel que actúa de manera racional, es decir, que actúa para alcanzar sus objetivos, basándose en la información que percibe y en su conocimiento del entorno. Más formalmente,

**Definition 5.1 (Wooldridge)** *Un agente es un sistema informático capaz de actuar autónomamente en algún entorno con el fin de alcanzar los objetivos que se le han delegado.*

**Definition 5.2 (Wooldridge updated)** *Cualquier proceso computacional dirigido por el objetivo capaz de interactuar con su entorno de forma **flexible** (Reactivo, Proactivo, Social) y **robusta***




Figure 5.1: Agente bucle

Un agente reactivo reacciona a los cambios del entorno. No tiene que ser el más rápido, pero la reacción debe ser útil. Un agente proactivo actúa para alcanzar sus objetivos, planifica y actúa en consecuencia. Un agente social interactúa con otros agentes.

En entornos complejos, un agente no tiene control completo sobre su entorno, sólo tiene un control parcial. Control parcial significa que el agente puede influir sobre el entorno con sus acciones. Una acción ejecutada por un agente puede fallar o tener el efecto deseado. En conclusión, los entornos son no deterministas y los agentes deben estar preparados para posibles fallos.

- ◊ Accesible vs inaccesible.  
Un entorno accesible es aquel en el que el agente puede obtener información completa, exacta y actualizada del estado del entorno.
- ◊ Determinista vs no determinista. Un entorno determinista es aquel en el que cualquier acción tiene un único efecto garantizado, no hay incertidumbre sobre el estado resultante de la ejecución de una acción  
El mundo físico puede a todos los efectos ser considerado como no determinista.  
Los entornos no deterministas presentan grandes problemas para el diseñador de agentes.
- ◊ Episódico vs no episódico  
En un entorno episódico el desempeño/actuación de un agente depende de un número discreto de episodios, no existiendo enlaces (relación) entre el desempeño de un agente en escenarios distintos. Los entornos episódicos son, desde el punto de vista del desarrollador de agentes, más sencillos porque el agente puede decidir que acción ejecutar basándose únicamente en el episodio actual, no necesita razonar sobre las interacciones entre el episodio actual y los episodios futuros.
- ◊ Estático vs dinámico  
Un entorno estático es aquel en el que se puede asumir que no se producen cambios excepto los provocados por la ejecución de acciones del agente. Un entorno dinámico es aquel que tiene otros procesos que operan en el, y que por lo tanto se producen cambios que están fuera del control del agente.

◊ Discreto vs continuo

Un entorno es discreto si en él hay un número fijo y finito de acciones y percepciones. El juego del ajedrez es un ejemplo de entorno discreto, y la conducción de un taxi un ejemplo de entorno continuo (AIMA, Russell and Norvig).

Asumimos que el entorno puede estar en uno cualquiera de los estados de un conjunto finito de estados instantáneos discreto (E):

$$E = s_1, s_2, \dots \quad (5.1)$$

- Se asume que los agentes tienen disponible un repertorio (conjunto finito) de posibles acciones que transforman el estado del entorno :

$$Ac = \alpha_1, \alpha_2, \dots \quad (5.2)$$

$$Acción : E \rightarrow A \quad (5.3)$$

$$Percibir : E \rightarrow P \quad (5.4)$$

$$Decisión : P^* \rightarrow A \quad (5.5)$$

$$Selección : I \rightarrow Ac \quad (5.6)$$

$$actualizar\_estados : I \times P \rightarrow I \quad (5.7)$$

- ◊  $P$  es un conjunto (no vacío) de percepciones (entradas perceptivas), que relaciona estados del entorno con percepciones
- ◊  $I$  es el conjunto de todos los estados internos del agente

## 5.1 Jason

Jason es un lenguaje de programación basado en agentes, que permite la programación de agentes inteligentes. Jason es un lenguaje de alto nivel, basado en la lógica, que permite la programación de agentes inteligentes, y es una extensión de AgentSpeak.

Los elementos fundamentales del Lenguaje son:

- ◊ **Creencias** (Beliefs)
- ◊ **Objetivos** (Goals)
- ◊ **Planes** (Plans, Intentions)

### 5.1.1 Creencias

Cada agente tiene una base de **creencias**, colección de literales representados como *predicados*.

- ◊ `tall(jhon)`.
- ◊ `likes(jhon, music)`

**Anotaciones** son detalles asociados a una creencia.

`busy(jhon)[expires(autum)]` Las anotaciones aportan “elegancia” al lenguaje y facilitan el manejo de la base de creencias.

Existen anotaciones que tienen un significado especial para el interprete. En particular la anotación **source**.

Hay tres tipos de fuentes de información para los agentes

- ◊ *Información perceptual*: aquella que percibe del entorno
  - `source(percept)`
  - `(colour(box1,blue)[source(percept)])`
- ◊ *Comunicación*: aquella que proviene de otro agente del sistema
  - `source(id agente)`
  - `(colour(box1,blue)[source(bob)])`
- ◊ *Notas mentales*: creencias que provienen del propio agente
  - `source(self)`
  - `(colour(box1,blue)[source(Self)])`

### 5.1.2 Objetivos

Existen dos tipos de objetivos en Jason:

1. **Achievement goals**(operador !): Expresan un estado del mundo que el agente desea conseguir.
  - ◊ `own(house)`
2. **Test goals**(operador ?): Usados normalmente para recuperar información de la base de creencias.
  - ◊ `bank_balance(BB)`

### 5.1.3 Planes

Un plan tiene tres partes

- ◊ **Triggering event:** Cambios en las creencias o objetivos del agente
- ◊ **Context:** Determinan si un plan es aplicable. Literales que deben ser una consecuencia lógica de la base de creencias para que el plan se instancie.
- ◊ **Body:** Sucesión de acciones que comporta el plan. Es una secuencia de acciones. Pueden existir nuevos subobjetivos.



Figure 5.2: Plan schema

#### 5.1.3.1 Cuerpo de un plan

El cuerpo del plan es secuencia de instrucciones separadas por “;”. Estas instrucciones pueden ser:

- ◊ **Actions:** Acciones externas que se denotan por un predicado. Proporcionan un “feedback”.
 

```
| rotate(leftarm, 45)
```
- ◊ **Achievement goals:** subobjetivos que deben ser alcanzados para que el plan continúe su ejecución (si en lugar de emplear “!” se emplea “!!”, el plan no suspenderá su ejecución).
 

```
| !!at(home); call(john) en lugar de !at(home); call(john).
```
- ◊ **Test goals:** Para recuperar información de la BB o verificar si el agente cree algo.
 

```
| ?coords(Tarjet,X,Y).
```
- ◊ **Mental Notes:** Anotación source(self). Sirven para añadir, modificar o eliminar nuevas creencias.
 

```
| +currenttargets(NumTargets); [Se anade]
      | -+currenttargets(NumTargets); [Se modifica]
```
- ◊ **InternalActions:** Son acciones que no modifican el entorno. Se diferencian de acciones del entorno por el carácter “.”.
 

```
| .print(...); .send(...);
```
- ◊ **Expressions:** Su sintaxis es semejante a la de Prolog.
 

```
| X >=Y*2
```
- ◊ **Plan Labels:** Los planes pueden estar etiquetados
 

```
| @labelte: ctxt<-body.
```

#### 5.1.3.2 Fallo de un Plan

- ◊ Un plan puede fallar por tres causas principales:
  - Falta de planes relevantes o aplicables para un “achievement goal”
  - Fallo de un “test goal”
  - Fallo de una acción
- ◊ Cuando un plan falla se genera un evento -!g (goal deletion event) si se generó por la adición de un “achievement goal” o “test goal”.
- ◊ El plan que se dispare por el fallo se añade a la pila de intenciones del plan que ha fallado.

### 5.1.4 Ejemplos

```
/* Creencias iniciales */
inicio.
/* Planes */
+inicio <- .print("Hola Mundo"). //plan que se dispara al inicio
```

```

/* Creencias iniciales */
fact(0,1).
/* Planes */
+fact(X,Y) : X < 5
<- +fact(X+1, (X+1) * Y ).
+fact(X,Y) : X = 5
<- .print("fact 5 == ", Y ).

/* Objetivos iniciales */
!dots.
!control.
/* Planes */
+!dots
<- .print("."); // imprime puntos en un bucle sin fin
!!dots.
+!control
<- .wait(30); // este plan es un bucle que activa y desactiva el otro plan
.suspend(dots); // suspende la intencion asociada al plan dots
.println;
.wait(200);
.resume(dots); // reactiva la intencion asociada al plan dots
!!control

// Un agente que soluciona el problema del mundo de bloques
/* Creencias iniciales y reglas */
clear(table).
clear(X) :- not(on(_,X)). // la creencia clear(X) es cierta cuando no tiene nada encima
tower([X]) :- on(X,table). // la torre X es cierta cuando X esta sobre la mesa
// X puede ser un bloque o varios
tower([X,Y|T]) :- on(X,Y) & tower([Y|T]).
// la torre va creciendo si un bloque X se pone sobre el bloque Y
/* Objetivos iniciales */
// Marca el estado final a alcanzar
!state([[a,e,b],[f,d,c],[g]]).

/* Planes */
// Alcanzar una torre
+!state([]) <- .print("Finalizado!").
+!state([H|T]) <- !tower(H); !state(T).
// Alcanzar un estado donde la torre esta construida
+!tower(T) : tower(T). // La torre deseada ya existe, no hay nada que hacer
+!tower([T]) <- !on(T,table). // La torre es de un solo elemento
+!tower([X,Y|T]) <- !tower([Y|T]); !on(X,Y). // divido el problema en subproblemas

```

## Chapter 6

# Ontologías

Una ontología define los términos y conceptos comunes empleados para describir y representar un área de conocimiento

Descripción mediante

- ◇ Clases
- ◇ Instancias
- ◇ Relaciones
- ◇ Propiedades
- ◇ Funciones / procesos
- ◇ Restricciones

Representación

- ◇ Frases que combinan la terminología para expresar relaciones entre los términos
- ◇ Estas frases aportan significado





## **Part II**

# **Machine Learning**



# Chapter 7

# N-Grams y FSA

## 7.1 N-Grams

“Hello, how are ...”

Dada secuencia de palabras  $w_1, w_2, \dots, w_n$ , queriamos predecir la siguiente palabra  $w_{n+1}$ . O, mejor, queriamos establecer la probabilidad de una secuencia de palabras  $P(w_1, w_2, \dots, w_n)$ , que se puede decomponer en

$$P(w_1, w_2, \dots, w_n) = P(w_1)P(w_2|w_1)P(w_3|w_1, w_2) \dots P(w_n|w_1, w_2, \dots, w_{n-1}) \tag{7.1}$$

Objectives:

- ◊ To assign a probability score to every word sequence
- ◊ To reflect a previous knowledge of a text source
  - To predict the most likely occurrence of words using its context

$$P(w) = P(w_1) \cdot \prod_{i=2}^m P(w_i|w_1, w_2, \dots, w_{i-1}) \text{ with } m \in \Sigma \tag{7.2}$$

La estimación de la probabilidad  $P(w)$  es prohibitivamente costoso cuando el tamaño del vocabulario  $|\Sigma|$  se hace enorme:  $|\Sigma|^{i-1}$  diferentes historias posibles.

Entonces, tal probabilidad se puede aproximar:

$$P(w) \approx \prod_{i=2}^m P(w_i|\phi(w_1, w_2, \dots, w_{i-1})) = \prod_{i=2}^m P(w_i|w_1, w_2, \dots, w_{i-1}) \tag{7.3}$$

La estimación de la probabilidad típicamente se hace usando relative frequency counts  $f(\cdot|\cdot)$ :

$$P(w_i|w_1, w_2, \dots, w_{i-1}) = f(w_i|w_1, w_2, \dots, w_{i-1}) = \frac{C(w_1, w_2, \dots, w_i)}{C(w_1, w_2, \dots, w_{i-1})} \tag{7.4}$$

### Example

$S = \{\text{el perro corre rapido, el perro corre rapido, el tren azul corre veloz, el tren azul corre veloz, el coche azul corre veloz, el coche azul corre veloz}\}$

1-gram counts:	2-gram counts:	3-gram counts:
<s> 6	<s> el 6	<s> el perro 2
el 6	el perro 2	<s> el tren 2
perro 2	el tren 2	<s> el coche 2
corre 6	el coche 2	el perro corre 2
rapido 2	perro corre 2	el tren azul 2
</s> 6	corre rapido 2	el coche azul 2
tren 2	corre veloz 4	perro corre rapido 2
azul 4	rapido </s> 2	corre rapido </s> 2
veloz 4	tren azul 2	corre veloz </s> 4
coche 2	azul corre 4	tren azul corre 2
	veloz </s> 4	azul corre veloz 4
	coche azul 2	coche azul corre 2

Figure 7.1: N-Grams Example

Un LM (Language Model, o Modelo de Lenguaje) es un modelo probabilístico que asigna una probabilidad a una secuencia de palabras. Un N-gram LM se dice *completo* si todas las posibles secuencias de palabras tienen una apropiada estimación de probabilidad.

El problema con esto es que hay eventos (secuencias de palabras) que casi nunca ocurren en el corpus de entrenamiento, y por lo tanto no tienen una estimación de probabilidad.

$$P(w_i|w_{i-n+1}^{i-1}) = \begin{cases} P^*(w_i|w_{i-n+1}^{i-1}) & \text{if } C(w_{i-n+1}^i) > 0 \\ \beta(w_{i-n+1}^{i-1})P(w_i|w_{i-n+2}^{i-1}) & \text{otherwise} \end{cases}$$

- $P^*(\cdot|\cdot)$ : discounted probability; reserves mass for unseen events
- $\beta$ : back-off weight; ensures the consistence of the model probabilities




Figure 7.2: 07/ngramBackOff

## Ejercicio

## 1-Gram

P(<s>) P(el) P(perro) P(corre) P(rapido) P(</s>)

6 6 2 6 2 6 81  
 - - - - - = - \* 10<sup>-6</sup>  
 34 34 34 34 34 34 64

34 perché la somma delle occorrenze delle singole parole è 40, a cui però dobbiamo togliere le 6 occorrenze

## 2-GRAM

P(<s>) P(el|<s>) P(perro|el) P(corre|perro) P(rapido|corre) P(</s>|rapido)

0 6 2 2 2 2 1  
 - - - - - = -  
 6 6 2 6 2 9

## 3-GRAM

P(<s>) P(el|<s>) P(perro|<s>el) P(corre|el perro) P(rapido|perro corre) P(</s>|corre rapido)

0 0 2 1 1 1  
 6

## 7.2 FSA - Finite State Automata

### Introduction to PFA Introduction to Probabilistic Finite-State Automata

- ◊ Free Monoid  $\Sigma^*$ : Given a finite set  $\Sigma$ ,  $\Sigma^+$  is the set of all strings with finite length composed of elements from  $\Sigma$

$$\Sigma^* = \Sigma^+ \cup \{\lambda\} (\lambda \text{ is the empty string}) \quad (7.5)$$

- ◊ Grammar:  $G = (N, \Sigma, R, S)$
- ◊  $N$ : Finite set of non-terminal symbols
- ◊  $\Sigma$ : Finite set of terminal symbols or primitives
- ◊  $S \in N$ : Initial non-terminal symbol or "axiom"
- ◊  $R \subset (N \cup \Sigma)^* N (N \cup \Sigma)^* \times (N \cup \Sigma)^*$ : set of rules

or productions A rule is written as:

$$\alpha \rightarrow \beta, \quad \alpha \in (N \cup \Sigma)^* N (N \cup \Sigma)^*, \quad \beta \in (N \cup \Sigma)^* \quad (7.6)$$

**Elemental derivation:**  $\Rightarrow G: \mu\alpha\delta \Rightarrow_G \mu\beta\delta \iff \exists(\alpha \rightarrow \beta) \in R, \mu, \delta \in (N \cup \Sigma)^*$

**Derivation  $\Rightarrow_G^*$ :** It is a finite sequence of elemental derivations. A derivation  $d$  can be written as the corresponding rule sequence of  $G$ . The set of derivations of  $y \in \Sigma^*$  (such that  $S \Rightarrow_G^* y$ ) is written as  $D_G(y)$ . A grammar  $G$  is ambiguous if  $\exists y \in \Sigma^*$  such that  $|D_G(y)| > 1$ .

**Language generated by a grammar  $G$ ,  $L(G)$ :**  $L(G) = \{y \in \Sigma^* \mid S \Rightarrow_G^* y\}$

- ◇ **Regular grammars:**  $G = (N, \Sigma, R, S)$ , Rules of  $R : A \rightarrow aB \vee A \rightarrow a, A, B \in N, a \in \Sigma$
- ◇ **Finite-state automaton:** (non deterministic)

$$A = (Q, \Sigma, \delta, q_0, F), \quad q_0 \in Q, \quad F \subseteq Q, \quad \delta : Q \times \Sigma \rightarrow 2^Q$$

- ◇ **Equivalence:** For each regular grammar there exists a finite-state automaton that recognizes the same language<sup>1</sup>

**Example:**

$$\begin{aligned} G &= (N, \Sigma, R, S); \\ \Sigma &= \{a, b\}; N = \{S, A_1, A_2\}; \\ R &= \{ S \rightarrow aA_1 \mid bA_2 \mid b, \\ A_1 &\rightarrow aA_1 \mid bA_2 \mid b, \\ A_2 &\rightarrow bA_2 \mid b \} \end{aligned} \quad \begin{array}{c} \text{Diagram of FSA with states } 0, 1, 2. \\ \text{State 0 is the start state. State 2 is a final state.} \\ \text{Transitions: } 0 \xrightarrow{a} 1, 0 \xrightarrow{b} 2, 1 \xrightarrow{a} 1, 1 \xrightarrow{b} 2, 2 \xrightarrow{b} 2. \end{array} \quad \begin{aligned} A &= \{Q, \Sigma, \delta, q_0, F\}; \\ Q &= \{0, 1, 2\}, \\ \Sigma &= \{a, b\}, \\ q_0 &= 0, F = \{2\} \end{aligned}$$

$$\mathcal{L}(G) = \{b, ab, bb, aab, abb, bbb, \dots, aaabbbb, \dots\} = \mathcal{L}(A)$$

Figure 7.3: FSA Equivalence example

Probabilistic Finite-state Automata (PFA): it is a tuple  $A = \langle Q, \Sigma, \delta, I, F, P \rangle$ , where:

- ◇  $Q$ : finite set of states
- ◇  $\Sigma$ : finite alphabet of symbols
- ◇  $\delta \subseteq Q \times \Sigma \times Q$ : transition function
- ◇  $I : Q \rightarrow \mathbb{R}^+ \cup \{0\}$ : initial state probabilities, with  $\sum_{q \in Q} I(q) = 1$
- ◇  $F : Q \rightarrow \mathbb{R}^+ \cup \{0\}$ : final state probabilities
- ◇  $P : \delta \rightarrow \mathbb{R}^+ \cup \{0\}$ : transition probabilities, with  $\forall q \in Q, \sigma \in \Sigma : \sum_{q' \in Q} P(q, \sigma, q') = 1$

A path in a PFA is a sequence of transitions:  $\pi = (q_0, a_1, q_1)(q_1, a_2, q_2) \dots (q_{n-1}, a_n, q_n)$

The probability of a path  $\pi$  is:

$$P(\pi) = I(q_0) \cdot \left( \prod_{i=1}^n P(q_{i-1}, a_i, q_i) \right) \cdot F(q_n) \quad (7.7)$$

The probability of a string  $x = a_1 a_2 \dots a_n$  is the sum of probabilities of all paths that generate  $x$ :

$$P_A(x) = \sum_{\pi \in \Pi_A(x)} P(\pi) \quad (7.8)$$

where  $\Pi_A(x)$  is the set of all paths in automaton  $A$  that generate string  $x$ .




Figure 7.4: Example of a Probabilistic Finite-state Automaton

## 7.2.1 Applications of PFA

PFA's are widely used in:

- ◇ Speech recognition
- ◇ Natural language processing
- ◇ Pattern recognition
- ◇ Biological sequence analysis

<sup>1</sup>The contrary isn't always true for stochastic languages.

### 7.2.2 Relation between N-Grams and PFA


Any n-gram model can be represented as a PFA, where:

- ◇ States represent histories (previous n-1 words)
- ◇ Transitions represent word emissions with their corresponding probabilities
- ◇ The resulting automaton has a specific structure reflecting the Markov property of n-gram models

## 7.3 Relación entre N-Grams y PFA

$n$ -grams can be represented using deterministic PFA

Examples of PFA representing 1-grams, 2-grams and 3-grams:



For **2-grams**:  $q = w_{i-1}$  and  $q' = w_i$ .

For **3-grams**:  $q = w_{i-2}w_{i-1}$  and  $q' = w_{i-1}w_i$ .

Figure 7.5: N-Gram representados como FSA

# Chapter 8

# Deep Learning

## 8.1 Introducción

La unidad básica es el llamado **neuron**, que implementa una *Función Discriminante Lineal* (LDF) con una función de activación. Un neurón recibe múltiples entradas, aplica pesos a estas entradas, suma los resultados y pasa esta suma a través de una función de activación para producir una salida.




Figure 8.1: Neuron

Matemáticamente, un neurón se puede representar como:

$$y = f \left( \sum_{i=1}^n w_i x_i + b \right)$$

Donde:

- ◊  $x_i$  son las entradas
- ◊  $w_i$  son los pesos
- ◊  $b$  es el sesgo (bias)
- ◊  $f$  es la función de activación

Neuronas pueden ser combinados en CAPAS (*layers*): lineal layers, convolutional layers, recurrent layers, etc. Capas pueden ser combinados en redes neuronales (*neural networks*).

## 8.2 Linear Discriminant Function and Perceptron

A classifier  $G$  in  $C$  classes can be defined by  $C$  discriminant functions  $g_c$ .

Classification rule ( $\vec{x} \in \mathbb{R}^D$ ) :  $\hat{c} = G(\vec{x}) = \text{argmax}_{c=1, \dots, C} g_c(\vec{x})$

When  $g_c$  are linear functions, they are called **Linear Discriminant Functions** (LDF)

$$g(\vec{x}) = w_0 + \sum_{i=1}^D \vec{w}_i x_i = w_0 + \vec{w}^t \vec{x}$$

$\vec{w}$  is the weights vector,  $w_0$  is the bias term In homogeneous notation:  $w = (w_0, \vec{w}^t)^t, x = (1, \vec{x}^t)^t$

$$g(\vec{x}) = w^t x$$

$G$  is a linear classifier when all  $g_c$  are linear functions, with parameters  $w_c$  Given a training dataset of samples in  $\mathbb{R}^D$ ,  $w_c$  can be estimated by using the **Perceptron** algorithm

The main limitation is that LDF provide linear frontiers only linearly separable classes can be properly separated. Using margin  $b$  allows for a non-optimal solution Combining several LDF in cascade does not solve the problem Result is still an LDF Solution: use of Activation Functions -> Logistic LDF (neuron)

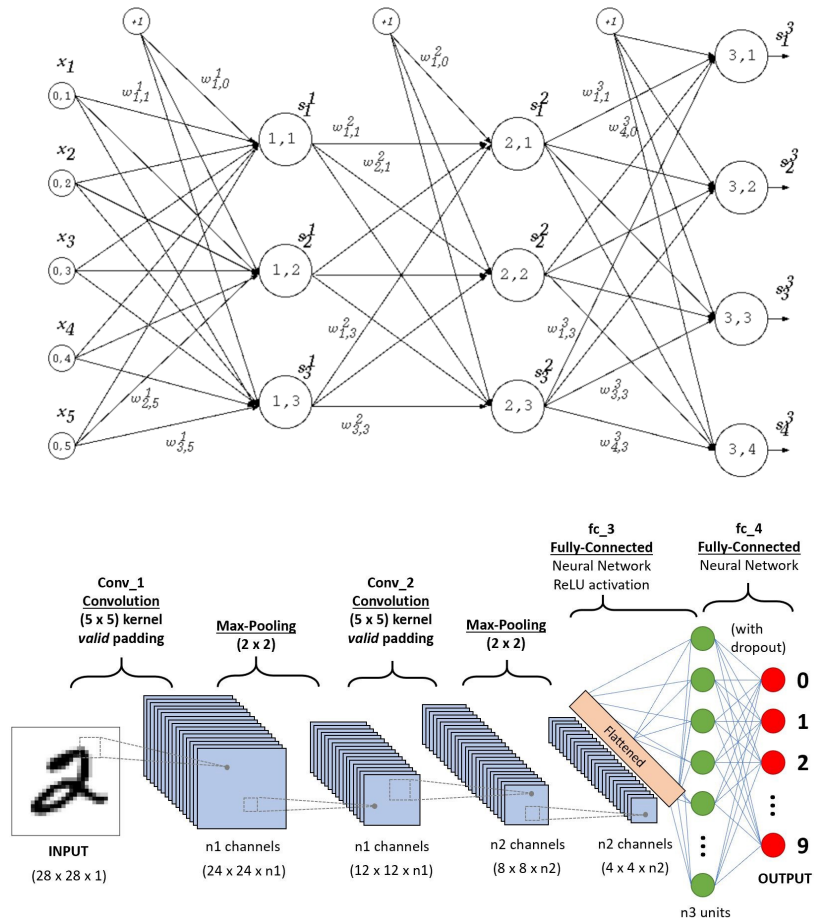


Figure 8.1: Capas y redes neuronales




Figure 8.2: Discriminant function Graph

**Algorithm 1** Perceptron algorithm

- 1: Perceptron algorithm
- 2: // Let be:  $w_j, 1 \leq j \leq C, C$  initial weight vectors;
- 3: //  $(\vec{x}_1, c_1), \dots, (\vec{x}_N, c_N), N$  training samples;
- 4: //  $\alpha \in \mathbb{R} > 0$ , "learningfactor",  $b \in \mathbb{R}$ , "margin".



```

// Let be:  $\mathbf{w}_j$ ,  $1 \leq j \leq C$ ,  $C$  initial weight vectors;
//  $(\vec{x}_1, c_1), \dots, (\vec{x}_N, c_N)$ ,  $N$  training samples;
//  $\alpha \in \mathbb{R}^{>0}$ , "learning factor";,  $b \in \mathbb{R}$ , "margin".
do {
    m = 0 // correctly classified samples
    for (n = 1; n ≤ N; n++) { // for each training sample
        i = cn; g =  $\mathbf{w}_i^T \mathbf{x}_n$ ; error=false // correct class score
        for (j = 1; j ≤ C; j++)
            if (j ≠ i) {
                if ( $\mathbf{w}_j^T \mathbf{x}_n + b > g$ ) { // incorrect classification
                     $\mathbf{w}_j = \mathbf{w}_j - \alpha \mathbf{x}_n$ ; // decrease wrong weights
                    error=true
                }
            }
        if (error)  $\mathbf{w}_i = \mathbf{w}_i + \alpha \mathbf{x}_n$ ; // increase correct weights
        else m = m + 1
    }
} while (m < N) // until all training samples well classified

```

Figure 8.3: Perceptron algorithm

